[과제 안내] 영화 대사 코퍼스 기반 이진 분류 모델 성능 비교 및 분석

머신러닝 실습 프로젝트 | 데이터 규모와 클래스 불균형 영향 분석

📌 과제 개요

목적 훈련 데이터의 양(Size)과 클래스 불균형(Class Imbalance)이 머신러닝 텍스트 분류 모델(SVM 및 TF-IDF)의 성능(정확도, 정밀도, 재현율)에 미치는 영향을 실험을 통해 직접 확인하고 분석합니다.

사용 도구 Python, Pandas, Scikit-Learn (`TfidfVectorizer`, SVC), Cornell Movie-Dialogs Corpus (스타워즈 캐릭터 대사 데이터)

📝 과제 세부 내용

[Part 1] 소규모 데이터셋 실험 (약 100개 데이터)

1. **데이터 준비:**
   - 루크(LUKE: Good)와 다스 베이더(DARTH VADER, EMPEROR: Bad)의 대사를 캐릭터당 제한을 두어 총 약 100~125개의 데이터셋(`starwars_4char_100lines.csv`)을 구축합니다.
2. **모델 학습 및 평가:**
   - `TfidfVectorizer`와 `SVM(kernel='linear')` 모델을 활용해 학습 및 테스트를 진행합니다.
3. **결과 분석:**
   - 테스트 정확도(Accuracy)와 함께 Bad (0) 클래스의 정밀도(Precision)와 재현율(Recall)을 확인하고, 데이터가 적고 불균형할 때 발생하는 문제점을 보고서에 기록합니다.

[Part 2] 대규모 데이터셋 실험 (약 1,000개 데이터)

1. **데이터 확장:**
   - 레아(LEIA: Good) 캐릭터를 추가하고, 캐릭터당 추출 대사 한도를 늘려 총 약 1,000개 이상의 확장된 데이터셋(`starwars_4char_1000lines.csv`)을 구축합니다.
2. **모델 학습 및 평가:**
   - 동일한 `TfidfVectorizer` 및 SVM 조건(또는 `class_weight='balanced'` 적용 여부)으로 모델을 다시 학습하고 평가합니다.
3. **결과 분석:**
   - Part 1과 비교했을 때 전체 정확도 및 소수 클래스(Bad)의 성능 지표가 어떻게 변화했는지 측정합니다.

[Part 3] 고찰 및 결론 (리포트 작성)

1. **데이터 양의 영향:** 데이터의 수가 100개에서 1,000개로 늘어났을 때 모델의 일반화 성능과 예측 안정성에 어떤 차이가 있었는지 서술하세요.
2. **불균형 문제 극복:** 소수 클래스(Bad)의 데이터가 부족할 때 발생한 현상과 이를 해결하기 위해 어떤 점이 유효했는지 본인의 생각을 작성하세요.

📦 제출물 안내

- **코드 파일:** Part 1과 Part 2를 각각 수행하고 결과를 출력하는 Jupyter Notebook(`.ipynb`) 또는 Python 스크립트(`.py`)
- **결과 캡처:** 각 실험 단계에서의 `classification_report` 실행 결과 화면 캡처
- **짧은 고찰 리포트:** 1페이지 내외의 비교 분석 내용 정리